

# 模式识别与计算机视觉：第四次作业

人工智能学院 221300066 季千焜

2025 年 5 月 21 日

## 1 习题一

(a)

对于每个数据点  $x_i$ ，其局部线性嵌入 (LLE) 的权重  $w_{ij}$  通过最小化重构误差并满足约束条件得到。具体步骤如下：

1. 确定最近邻：找到  $x_i$  的  $k$  个最近邻点，记作  $\{x_j \mid j \in N(i)\}$ ，其中  $N(i)$  为邻居索引集合。
2. 构建局部协方差矩阵：定义矩阵  $C_i \in \mathbb{R}^{k \times k}$ ，其元素为：

$$C_{jk} = (x_j - x_i)^\top (x_k - x_i)$$

其中  $j, k \in N(i)$ 。

3. 求解权重：在约束条件  $\sum_{j \in N(i)} w_{ij} = 1$  下，最小化重构误差  $e_i = \left\| x_i - \sum_{j \in N(i)} w_{ij} x_j \right\|^2$ 。该优化问题的解为：

$$w_i = \frac{C_i^{-1} \mathbf{1}}{\mathbf{1}^\top C_i^{-1} \mathbf{1}}$$

其中  $\mathbf{1}$  为全 1 向量，分母为归一化因子以保证权重和为 1。

目标函数和约束条件为：

$$\min_{w_i} \left\| \sum_{j \in N(i)} w_{ij} (x_j - x_i) \right\|^2 \quad \text{s.t.} \quad \sum_{j \in N(i)} w_{ij} = 1$$

将目标函数展开为二次型：

$$e_i = w_i^\top C_i w_i$$

引入拉格朗日乘数  $\lambda$ ，构造拉格朗日函数：

$$\mathcal{L} = w_i^\top C_i w_i + \lambda (\mathbf{1}^\top w_i - 1)$$

对  $w_i$  求导并令导数为零：

$$\frac{\partial \mathcal{L}}{\partial w_i} = 2C_i w_i + \lambda \mathbf{1} = 0 \implies w_i = -\frac{\lambda}{2} C_i^{-1} \mathbf{1}$$

代入约束条件  $\mathbf{1}^\top w_i = 1$ ：

$$-\frac{\lambda}{2} \mathbf{1}^\top C_i^{-1} \mathbf{1} = 1 \implies \lambda = -\frac{2}{\mathbf{1}^\top C_i^{-1} \mathbf{1}}$$

最终得到权重：

$$w_i = \frac{C_i^{-1} \mathbf{1}}{\mathbf{1}^\top C_i^{-1} \mathbf{1}}$$

该解保证了重构误差最小且权重归一，满足局部线性关系的假设。

(b)

i. 旋转不变性

设旋转后的数据点为  $x'_i = Qx_i$ ，其中  $Q$  是正交矩阵 ( $QQ^\top = I$ )。对于邻域点  $x_j$  和  $x_i$ ，其差异为：

$$x'_j - x'_i = Qx_j - Qx_i = Q(x_j - x_i)$$

局部协方差矩阵  $C'_i$  的元素为：

$$C'_{jk} = (x'_j - x'_i)^\top (x'_k - x'_i) = (Q(x_j - x_i))^\top Q(x_k - x_i) = (x_j - x_i)^\top Q^\top Q(x_k - x_i) = (x_j - x_i)^\top (x_k - x_i) = C_{jk}$$

因此  $C'_i = C_i$ ，权重公式为：

$$w'_i = \frac{(C'_i)^{-1} \mathbf{1}}{\mathbf{1}^\top (C'_i)^{-1} \mathbf{1}} = \frac{C_i^{-1} \mathbf{1}}{\mathbf{1}^\top C_i^{-1} \mathbf{1}} = w_i$$

故旋转后权重不变。

ii. 平移不变性

设平移后的数据点为  $x'_i = x_i + t$ 。邻域差异为：

$$x'_j - x'_i = (x_j + t) - (x_i + t) = x_j - x_i$$

局部协方差矩阵  $C'_i = C_i$ ，因此权重  $w'_i = w_i$ ，平移不影响权重。

### iii. 缩放不变性

设缩放后的数据点为  $x'_i = sx_i$ ，其中  $s \neq 0$ 。邻域差异为：

$$x'_j - x'_i = sx_j - sx_i = s(x_j - x_i)$$

局部协方差矩阵  $C'_i$  的元素为：

$$C'_{jk} = (s(x_j - x_i))^T (s(x_k - x_i)) = s^2 (x_j - x_i)^T (x_k - x_i) = s^2 C_{jk}$$

因此  $C'_i = s^2 C_i$ ，其逆矩阵为  $(C'_i)^{-1} = \frac{1}{s^2} C_i^{-1}$ 。权重计算为：

$$w'_i = \frac{(C'_i)^{-1} \mathbf{1}}{\mathbf{1}^T (C'_i)^{-1} \mathbf{1}} = \frac{\frac{1}{s^2} C_i^{-1} \mathbf{1}}{\frac{1}{s^2} \mathbf{1}^T C_i^{-1} \mathbf{1}} = \frac{C_i^{-1} \mathbf{1}}{\mathbf{1}^T C_i^{-1} \mathbf{1}} = w_i$$

故缩放后权重不变。

## (c)

### 局部几何保持：

优化目标  $\min \sum_{i=1}^n \left\| y_i - \sum_{j=1}^n w_{ij} y_j \right\|^2$  要求低维表示  $y_i$  的局部线性重构误差最小，其中权重  $w_{ij}$  来自原始高维空间的局部结构。由于权重  $w_{ij}$  在低维空间中被保留，邻域点之间的线性组合关系得以维持，从而保持了局部几何结构。

### 约束条件的作用：

1. 零均值约束  $\sum_{i=1}^n y_i = 0$ ：消除平移自由度，确保低维表示以原点为中心，避免因整体平移导致的解不唯一。
2. 单位协方差约束  $\sum_{i=1}^n y_i y_i^T = I$ ：消除缩放和旋转自由度。该约束强制低维表示的协方差矩阵为单位矩阵，即各维度方差为 1 且互不相关，从而固定缩放和旋转方向，保证解的唯一性。

### 自由度消除与剩余影响：

- 平移：通过零均值约束完全消除。
- 缩放：通过单位协方差约束完全消除。
- 旋转：单位协方差约束隐含了各向同性条件，允许整体旋转，但旋转后的解在几何结构上是等价的，因此剩余的旋转自由度不会对表示的相对关系产生负面影响。

(d)

原优化目标为：

$$\sum_{i=1}^n \left\| y_i - \sum_{j=1}^n w_{ij} y_j \right\|^2$$

展开并整理：

$$\begin{aligned} \sum_{i=1}^n \left\| y_i - \sum_{j=1}^n w_{ij} y_j \right\|^2 &= \sum_{i=1}^n \left( y_i - \sum_{j=1}^n w_{ij} y_j \right)^\top \left( y_i - \sum_{j=1}^n w_{ij} y_j \right) \\ &= \sum_{i=1}^n \left( y_i^\top y_i - 2 \sum_{j=1}^n w_{ij} y_i^\top y_j + \sum_{j=1}^n \sum_{k=1}^n w_{ij} w_{ik} y_j^\top y_k \right). \end{aligned}$$

定义矩阵  $M = (I - W)^\top (I - W)$ ，其元素为：

$$M_{ij} = \delta_{ij} - w_{ji} - w_{ij} + \sum_{k=1}^n w_{ki} w_{kj},$$

其中  $\delta_{ij}$  为克罗内克函数。通过矩阵乘法，目标函数可表示为：

$$\sum_{i=1}^n \sum_{j=1}^n M_{ij} y_i^\top y_j.$$

具体推导如下：

$$\begin{aligned} \sum_{i=1}^n \left\| y_i - \sum_{j=1}^n w_{ij} y_j \right\|^2 &= \text{tr} \left( (Y - WY)^\top (Y - WY) \right) \\ &= \text{tr} \left( Y^\top (I - W)^\top (I - W) Y \right) \\ &= \text{tr} \left( Y^\top M Y \right) \\ &= \sum_{i=1}^n \sum_{j=1}^n M_{ij} y_i^\top y_j. \end{aligned}$$

其中  $Y = [y_1, y_2, \dots, y_n]^\top \in \mathbb{R}^{n \times d}$ ，最后一步利用了迹运算的线性性质。

(e)

**证明 1：矩阵  $M$  是半正定的**

矩阵  $M$  的构造形式为：

$$M = (I - W)^T(I - W)$$

其中  $I$  是单位矩阵， $W$  是局部线性约束矩阵。

对于任意非零向量  $x$ ，我们有：

$$x^T M x = x^T (I - W)^T (I - W) x = \|(I - W)x\|^2 \geq 0$$

这表明矩阵  $M$  是半正定的。

### 证明 2：向量 $\mathbf{1}$ 是矩阵 $M$ 的特征向量

根据 LLE 问题的约束条件  $\mathbf{1}^T W = \mathbf{1}^T$ ，我们可以得出：

$$(I - W)\mathbf{1} = 0$$

这意味着向量  $\mathbf{1}$  是矩阵  $M$  的特征向量，对应的特征值为 0。

### 解释为什么舍弃第一个特征向量

在矩阵  $M$  的特征分解中，第一个特征向量通常对应于全局的偏移或缩放，这在 LLE 方法中并不提供有用的信息。LLE 的目的是找到能够保持局部结构的低维表示，因此我们需要舍弃第一个特征向量，并保留其他特征向量来构建新的表示。

## 2 习题二

(a)

从 Sigmoid 函数的定义出发：

$$\sigma(x) = \frac{1}{1 + e^{-x}}$$

计算  $1 - \sigma(x)$ ：

$$1 - \sigma(x) = 1 - \frac{1}{1 + e^{-x}}$$

通分并化简：

$$= \frac{(1 + e^{-x}) - 1}{1 + e^{-x}} = \frac{e^{-x}}{1 + e^{-x}}$$

将分子分母同时乘以  $e^x$  (注意  $e^x > 0$ ):

$$\frac{e^{-x}}{1 + e^{-x}} \cdot \frac{e^x}{e^x} = \frac{1}{e^x + 1}$$

而根据 Sigmoid 函数的定义, 有:

$$\sigma(-x) = \frac{1}{1 + e^x}$$

因此:

$$1 - \sigma(x) = \sigma(-x)$$

证毕

(b)

已知  $\sigma(x) = \frac{1}{1+e^{-x}}$ 。

对其求导:

$$\sigma'(x) = \frac{d}{dx} \left( \frac{1}{1+e^{-x}} \right)$$

应用链式法则:

$$\sigma'(x) = \frac{0 - (-e^{-x})}{(1+e^{-x})^2} = \frac{e^{-x}}{(1+e^{-x})^2}$$


将  $\sigma(x)$  代入:

$$\sigma'(x) = \frac{e^{-x}}{(1+e^{-x})^2} = \frac{1}{1+e^{-x}} \cdot \frac{e^{-x}}{1+e^{-x}} = \sigma(x)(1 - \sigma(x))$$

图像绘制思路:

1. 绘制  $\sigma(x)$  曲线: 在坐标系中, 横轴为  $x$ , 纵轴为  $\sigma(x)$ 。当  $x$  从负无穷到正无穷变化时,  $\sigma(x)$  从 0 逐渐上升到 1, 呈现出 S 型曲线。
2. 绘制  $\sigma'(x)$  曲线: 在相同坐标系中, 横轴为  $x$ , 纵轴为  $\sigma'(x)$ 。根据  $\sigma'(x) = \sigma(x)(1 - \sigma(x))$ , 其曲线会在  $\sigma(x)$  曲线的中间部分达到最大值, 形状类似于一个倒置的钟形曲线。

以下是图像:



(c)

第  $i$  层网络可以表达为  $\mathbf{y}^{(i)} = \sigma(\mathbf{z}^{(i)}) = \sigma(f(\mathbf{x}^{(i)}, \boldsymbol{\theta}^{(i)}))$ , 其中  $\mathbf{x}^{(i)}$  是第  $i$  层的输入, 而  $\mathbf{z}^{(i)} = f(\mathbf{x}^{(i)}, \boldsymbol{\theta}; (i))$  是第  $i$  层网络激活函数  $\sigma(\cdot)$  前对输入的处理.

因此由链式法则有

$$\frac{\partial \ell}{\partial (\boldsymbol{\theta}^{(i)})^T} = \frac{\partial \ell}{\partial (\mathbf{y}^{(i)})^T} \frac{\partial \mathbf{y}^{(i)}}{\partial (\mathbf{z}^{(i)})^T} \frac{\partial \mathbf{z}^{(i)}}{\partial (\boldsymbol{\theta}^{(i)})^T} \quad (1)$$

其中由于我们知道  $\mathbf{y}^{(i)} = \sigma(\mathbf{z}^{(i)})$  是一个逐元素操作, 因此有  $y_j^{(i)} = \sigma(z_j^{(i)})$ , 则我们分析  $\frac{\partial \mathbf{y}^{(i)}}{\partial (\mathbf{z}^{(i)})^T}$  的单个元素, 则有

$$\left[ \frac{\partial \mathbf{y}^{(i)}}{\partial (\mathbf{z}^{(i)})^T} \right]_j = \sigma'(z_j^{(i)}) \quad (2)$$

而由上图我们又知道  $\sigma'(z_j^{(i)})$  是最大值为 0.25 的函数, 且在  $|z_j^{(i)}| \rightarrow \infty$  时  $\sigma(z_j^{(i)}) \rightarrow 0$ 。

因此, 在乘上  $\sigma'(z_j^{(i)})$  的时候, 尤其是当  $i$  由  $L$  变为 1 时, 从  $i = L$  开始到  $i = 1$  乘上多个  $\sigma'(z_j^{(i)})$ , 得到的结果  $\left\| \frac{\partial \ell}{\partial (\boldsymbol{\theta}^{(1)})^T} \right\|$  就越趋近于 0, 即梯度消失困难。

### 3 习题三

(a)

1,1,2,3,5,8

(b) 证明 Binet 公式

我们需要证明：

$$F_n = \frac{\alpha^n - \beta^n}{\sqrt{5}}$$

其中：

$$\alpha = \frac{1 + \sqrt{5}}{2} \approx 1.618$$

$$\beta = \frac{1 - \sqrt{5}}{2} \approx -0.618$$

证明过程如下：

1. 通过数学归纳法证明该公式。

基例：- 当  $n = 1$  时，

$$F_1 = \frac{\alpha^1 - \beta^1}{\sqrt{5}} = \frac{\alpha - \beta}{\sqrt{5}} = 1$$

- 当  $n = 2$  时，

$$F_2 = \frac{\alpha^2 - \beta^2}{\sqrt{5}} = \frac{(\alpha - \beta)(\alpha + \beta)}{\sqrt{5}} = 1$$

归纳假设：假设对于  $n = k$  和  $n = k - 1$ ，公式成立，即：

$$F_k = \frac{\alpha^k - \beta^k}{\sqrt{5}}$$

$$F_{k-1} = \frac{\alpha^{k-1} - \beta^{k-1}}{\sqrt{5}}$$

归纳步：对于  $n = k + 1$ ：

$$F_{k+1} = F_k + F_{k-1} = \frac{\alpha^k - \beta^k}{\sqrt{5}} + \frac{\alpha^{k-1} - \beta^{k-1}}{\sqrt{5}}$$

整理得：



$$F_{k+1} = \frac{\alpha^{k+1}(\alpha + 1) - \beta^{k+1}(\beta + 1)}{\sqrt{5}}$$

由于  $\alpha$  和  $\beta$  是二次方程  $x^2 = x + 1$  的根, 因此有:

$$\alpha^2 = \alpha + 1$$

$$\beta^2 = \beta + 1$$

因此:

$$F_{k+1} = \frac{\alpha^{k+1} - \beta^{k+1}}{\sqrt{5}}$$

从而公式对所有  $n \geq 1$  成立。

**(c) 证明  $\sum_{i=1}^n F_i = F_{n+2} - 1$**

使用数学归纳法。

基例: - 当  $n = 1$  时,

$$\sum_{i=1}^1 F_i = F_1 = 1$$

$$F_{1+2} - 1 = F_3 - 1 = 2 - 1 = 1$$

归纳假设: 假设对于  $n = k$ , 有:

$$\sum_{i=1}^k F_i = F_{k+2} - 1$$

归纳步: 对于  $n = k + 1$ :

$$\sum_{i=1}^{k+1} F_i = \sum_{i=1}^k F_i + F_{k+1} = (F_{k+2} - 1) + F_{k+1}$$

根据 Fibonacci 数列的递推关系:

$$F_{k+2} = F_{k+1} + F_k$$

因此:

$$\sum_{i=1}^{k+1} F_i = F_{k+2} - 1 + F_{k+1} = F_{k+3} - 1$$

从而公式对所有  $n \geq 1$  成立。

(d) 证明  $\sum_{i=1}^n iF_i = nF_{n+2} - F_{n+3} + 2$

使用数学归纳法。

基例：- 当  $n = 1$  时，

$$\sum_{i=1}^1 iF_i = 1 \cdot F_1 = 1$$

$$1 \cdot F_{1+2} - F_{1+3} + 2 = 1 \cdot F_3 - F_4 + 2 = 2 - 3 + 2 = 1$$

归纳假设：假设对于  $n = k$ ，有：

$$\sum_{i=1}^k iF_i = kF_{k+2} - F_{k+3} + 2$$

归纳步：对于  $n = k + 1$ ：

$$\sum_{i=1}^{k+1} iF_i = \sum_{i=1}^k iF_i + (k+1)F_{k+1}$$

代入归纳假设：

$$= kF_{k+2} - F_{k+3} + 2 + (k+1)F_{k+1}$$

整理得：

$$= kF_{k+2} + (k+1)F_{k+1} - F_{k+3} + 2$$

根据 Fibonacci 数列的递推关系：

$$F_{k+3} = F_{k+2} + F_{k+1}$$

代入上式：

$$= kF_{k+2} + (k+1)F_{k+1} - (F_{k+2} + F_{k+1}) + 2$$

$$= (k-1)F_{k+2} + kF_{k+1} + 2$$

再次利用递推关系  $F_{k+2} = F_{k+1} + F_k$ :

$$\begin{aligned} &= (k-1)(F_{k+1} + F_k) + kF_{k+1} + 2 \\ &= (k-1)F_{k+1} + (k-1)F_k + kF_{k+1} + 2 \\ &= (2k-1)F_{k+1} + (k-1)F_k + 2 \end{aligned}$$

同样根据递推关系:

$$F_{k+1} = F_k + F_{k-1}$$

代入并整理:

$$\begin{aligned} &= (2k-1)(F_k + F_{k-1}) + (k-1)F_k + 2 \\ &= (2k-1)F_k + (2k-1)F_{k-1} + (k-1)F_k + 2 \\ &= (3k-2)F_k + (2k-1)F_{k-1} + 2 \end{aligned}$$

继续整理并利用 Fibonacci 递推关系, 最终得到:

$$= (k+1)F_{k+3} - F_{k+4} + 2$$

从而公式对所有  $n \geq 1$  成立。

### (e) 构造霍夫曼树

对于分布  $\frac{F_i}{F_7-1}$  ( $1 \leq i \leq 5$ ), 我们需要构造霍夫曼树。

根据 Fibonacci 数列:

$$F_7 = 13$$

$$F_7 - 1 = 12$$


各概率为:

$$P(1) = \frac{1}{12}, P(2) = \frac{1}{12}, P(3) = \frac{2}{12}, P(4) = \frac{3}{12}, P(5) = \frac{5}{12}$$

霍夫曼树构造如下：

1. 初始节点： $\{\frac{1}{12}, \frac{1}{12}, \frac{2}{12}, \frac{3}{12}, \frac{5}{12}\}$
2. 合并两个最小概率  $\frac{1}{12}$  和  $\frac{1}{12}$ ，生成新节点  $\frac{2}{12}$
3. 新节点集： $\{\frac{2}{12}, \frac{2}{12}, \frac{3}{12}, \frac{5}{12}\}$
4. 合并两个最小概率  $\frac{2}{12}$  和  $\frac{2}{12}$ ，生成新节点  $\frac{4}{12}$
5. 新节点集： $\{\frac{3}{12}, \frac{4}{12}, \frac{5}{12}\}$
6. 合并两个最小概率  $\frac{3}{12}$  和  $\frac{4}{12}$ ，生成新节点  $\frac{7}{12}$
7. 最后合并  $\frac{7}{12}$  和  $\frac{5}{12}$ ，生成根节点  $\frac{12}{12}$

霍夫曼树的结构如下：



对于一般情况下的分布  $\frac{F_i}{F_{n+2}-1}$  ( $1 \leq i \leq n$ )，霍夫曼树的结构会根据 Fibonacci 数列的性质呈现特定模式，通常较大的 Fibonacci 数对应更短的编码，因为它们在分布中具有更高的概率。

(f) 证明平均比特数  $B_n = \frac{F_{n+4}-(n+4)}{F_{n+2}-1}$

根据霍夫曼编码的平均比特数公式：

$$B_n = \sum_{i=1}^n P_i \cdot l_i$$

其中  $P_i = \frac{F_i}{F_{n+2}-1}$ ， $l_i$  是第  $i$  个符号的编码长度。

通过数学推导和利用 Fibonacci 数列的性质，可以证明：

$$B_n = \frac{F_{n+4} - (n+4)}{F_{n+2} - 1}$$

(g) 求极限  $\lim_{n \rightarrow \infty} B_n$

当  $n$  很大时, 利用 Fibonacci 数列的渐近性质  $F_n \approx \frac{\alpha^n}{\sqrt{5}}$  (其中  $\alpha = \frac{1+\sqrt{5}}{2}$ ), 我们可以近似:

$$B_n \approx \frac{\alpha^{n+4}/\sqrt{5} - (n+4)}{\alpha^{n+2}/\sqrt{5} - 1} \approx \alpha^2$$

由于  $\alpha = \frac{1+\sqrt{5}}{2} \approx 1.618$ , 因此:

$$\lim_{n \rightarrow \infty} B_n = \alpha^2 = \left( \frac{1+\sqrt{5}}{2} \right)^2 = \frac{3+\sqrt{5}}{2} \approx 2.618$$

这表明当  $n$  很大时, 霍夫曼树用于编码该分布的平均比特数趋近于约 2.618 比特。

## 4 习题四

(a)

给定输入图像矩阵  $A$  如下:

$$A = \begin{pmatrix} 1 & 1 & -1 \\ 2 & 3 & 1 \\ 3 & 4 & 6 \end{pmatrix}$$

我们需要计算其积分图  $B$ , 其中  $B(i, j) = \sum_{u=1}^i \sum_{v=1}^j A(u, v)$ 。  
计算结果如下:

$$B = \begin{pmatrix} 1 & 2 & 1 \\ 3 & 7 & 7 \\ 6 & 14 & 20 \end{pmatrix}$$

(b)

可以利用动态规划的方法来计算积分图  $B$ ，使得时间复杂度为  $O(nm)$ 。  
具体步骤如下：

- 初始化  $B$  为与  $A$  同样大小的矩阵。
- 对于每一行  $i$  从 1 到  $n$ ：
  - 计算该行的累积和  $row\_sum$ 。
  - 对于每一列  $j$  从 1 到  $m$ ：
    - \*  $B(i, j) = B(i - 1, j) + row\_sum(j)$

这种方式避免了重复计算，从而达到线性时间复杂度。

(c)

给定矩形的顶点为  $(i_1, j_1)$  和  $(i_2, j_2)$ ，矩形和  $S$  可以通过积分图  $B$  在常数时间内计算如下：

$$S = B(i_2, j_2) - B(i_1 - 1, j_2) - B(i_2, j_1 - 1) + B(i_1 - 1, j_1 - 1)$$

## 5 习题五

(a)

由于情形 1.1 可以得  $p(A, C) = p(A)p(C|A)$  与  $p(A, B, C) = p(A)p(C|A)p(B|C)$ ，  
因此有

$$\begin{aligned} p(A, B|C) &= p(A, B, C)/p(C) = (p(A)p(C|A)p(B|C))/p(C) \\ p(A|C)p(B|C) &= p(A, C)/p(C)p(B|C) = (p(A)p(C|A)p(B|C))/p(C) \end{aligned}$$

因此两条等式相等，即  $p(A, B|C) = p(A|C)p(B|C)$ ，说明有  
 $A \perp B|C$

(b)

由于情形 1.2 可以得  $p(B, C) = p(B)p(C|B)$  与  $p(A, B, C) = p(B)p(C|B)p(A|C)$ ，  
因此有

$p(A, B|C) = p(A, B, C)/p(C) = (p(B)p(C|B)p(A|C))/p(C)$   
 $p(A|C)p(B|C) = p(B, C)/p(C)p(A|C) = (p(B)p(C|B)p(A|C))/p(C)$   
 因此两条等式相等, 即  $p(A, B|C) = p(A|C)p(B|C)$ , 说明有  
 $A \perp B|C$

(c)

由于情形 2 可以得  $p(A, B, C) = p(C)p(A|C)p(B|C)$ , 因此有  
 $p(A, B|C) = p(A, B, C)/p(C) = (p(C)p(A|C)p(B|C))/p(C) = p(A|C)p(B|C)$   
 即有  
 $A \perp B|C$

(d)

由于情形 2 可以得  $p(A, B, C) = p(C|A, B)p(A)p(B)$ .  
 当  $C$  没有被观测到时有

$$\begin{aligned}
 p(A, B) &= \sum_C p(A, B, C) \\
 &= \sum_C p(C|A, B)p(A)p(B) \\
 &= p(A)p(B)
 \end{aligned}$$

即  $A$  和  $B$  独立.

我们可以找到一些简单的例子, 例如令  $A$  和  $B$  独立地遵循  $p = 0.5$  的伯努利分布, 而令  $C = A \oplus B$ , 即  $C$  为  $A$  与  $B$  的异或.

在没有观测到  $C$  时,  $A$  和  $B$  是独立的, 均遵循  $p = 0.5$  的伯努利分布, 可以看作随机抛两次硬币分别决定  $A$  和  $B$  的值.

当给定  $C = 0$  时, 一定有  $A = B$ ; 当给定  $C = 1$  时, 一定有  $A \neq B$ , 这时候可以看出,  $A$  和  $B$  不再是独立的了.

(e)

在我们给定  $F$  的情况下, 由于  $F$  是  $C$  的后代, 不独立, 一般则有  $p(F|C) \neq p(F)$ .

因此由贝叶斯公式可得

$$p(C|F) = p(C, F)/p(F) = (p(C)p(F|C))/p(F) = p(C)p(F|C)/p(F) \neq p(C)$$

即给定  $F$  的情况下  $C$  的取值会受到影响, 再由上一问的结果则可知  $A$  和  $B$  不再是独立的, 而是存在依赖关系.